

Proposta de Arquitetura da Solução: Do Modelo White-Box ao Modelo Híbrido Grey-Box

Projeto de Conclusão de Curso (TCC) -- Engenharia Química -- UFMG

Alunos: Daniel Couto Vieira, Guilherme Moura de Sousa Franco, Matheus Henrique Borba Póvoas, Rodrigo Amaral da Mata

Orientador: Prof. Dr. Fabrício Eduardo Bortot Coelho

Data: Setembro de 2026

1. STATUS ATUAL

Desenvolvemos uma estrutura modular em Python que reproduz as equações de conservação e balanço populacional:

```
scripts/
├─ data_loader.py          <- Ingestão padronizada dos 128 pontos (Tabelas A1.1 e A1.4)
├─ kinetics.py             <- Cinética de Arrhenius, estequiometria do ácido e taxa v(t)
├─ population_balance.py   <- PBM via Método das Características com distribuição RRB
└─ diagnostico_residuo.py <- Execução do PBM e cálculo do resíduo Delta_X
```

Resultados Obtidos pelo White-Box Puro ($\alpha = 0$):

- R^2 Global (128 pontos):** 0,9253 (explica 92,5% da variância experimental).
- RMSE (Erro Médio Quadrático):** 0,0886 (8,86%).
- MAE (Erro Médio Absoluto):** 0,0507 (5,07%).
- Consistência Física:** 100% das restrições atendidas ($0 \leq X \leq 1$ e esgotamento estequiométrico quando $\eta < 1,0$).

1.1 Tabela de Conversões Experimentais (X_{Zn}^{exp})

(Dados reais das Tabelas A1.1 e A1.4 da dissertação de Fabrício Bortot Coelho, 2017)

Ensaio	η	CA0 (mol/L)	0 min	0,5 min	1 min	2 min	3 min	4 min	5 min	15 min
1	0,5	0,1	0,00	0,42	0,46	0,46	0,49	0,51	0,49	0,50
2	3,1	0,1	0,00	0,82	0,90	0,95	0,97	0,97	0,99	1,00
3	0,5	0,5	0,00	0,45	0,48	0,49	0,52	0,50	0,49	0,50
4	0,5	1,0	0,00	0,50	0,47	0,51	0,47	0,53	0,51	0,50
5	0,5	1,5	0,00	0,49	0,49	0,47	0,49	0,49	0,47	0,49
6	1,0	0,1	0,00	0,75	0,78	0,80	0,85	0,87	0,85	0,87
7	3,1	0,5	0,00	0,88	0,93	0,98	0,99	1,00	0,99	1,01
8	1,0	0,5	0,00	0,83	0,82	0,85	0,86	0,87	0,86	0,87
9	1,0	1,0	0,00	0,83	0,84	0,85	0,85	0,83	0,84	0,85
10	1,0	1,5	0,00	0,84	0,83	0,83	0,83	0,83	0,84	0,85
11	1,5	0,1	0,00	0,86	0,85	0,88	0,97	0,94	0,96	0,98
12	3,1	1,0	0,00	0,96	1,00	1,00	0,99	0,99	0,99	1,00
13	1,5	0,5	0,00	0,92	0,92	0,95	0,95	0,95	0,95	0,97
14	1,5	1,0	0,00	0,91	0,96	0,95	0,97	0,95	0,98	0,97
15	1,5	1,5	0,00	0,91	0,94	0,95	0,94	0,96	0,96	0,97
16	3,1	1,5	0,00	0,98	0,98	0,96	0,99	0,99	1,00	1,00

1.2 Tabela de Conversões do Modelo White-Box Puro (X_{PBM})

(Predições mecanicistas obtidas via Balanço Populacional analítico com $\alpha = 0$)

Ensaio	η	CA0 (mol/L)	0 min	0,5 min	1 min	2 min	3 min	4 min	5 min	15 min
1	0,5	0,1	0,00	0,32	0,42	0,48	0,50	0,50	0,50	0,50
2	3,1	0,1	0,00	0,45	0,68	0,88	0,95	0,98	0,99	1,00
3	0,5	0,5	0,00	0,49	0,50	0,50	0,50	0,50	0,50	0,50
4	0,5	1,0	0,00	0,50	0,50	0,50	0,50	0,50	0,50	0,50
5	0,5	1,5	0,00	0,50	0,50	0,50	0,50	0,50	0,50	0,50
6	1,0	0,1	0,00	0,39	0,57	0,72	0,80	0,84	0,87	0,95
7	3,1	0,5	0,00	0,92	0,99	1,00	1,00	1,00	1,00	1,00
8	1,0	0,5	0,00	0,77	0,87	0,93	0,95	0,96	0,97	0,99
9	1,0	1,0	0,00	0,87	0,93	0,96	0,98	0,98	0,99	1,00
10	1,0	1,5	0,00	0,91	0,95	0,98	0,98	0,99	0,99	1,00
11	1,5	0,1	0,00	0,42	0,62	0,81	0,89	0,93	0,96	1,00
12	3,1	1,0	0,00	0,99	1,00	1,00	1,00	1,00	1,00	1,00
13	1,5	0,5	0,00	0,86	0,96	1,00	1,00	1,00	1,00	1,00
14	1,5	1,0	0,00	0,96	1,00	1,00	1,00	1,00	1,00	1,00
15	1,5	1,5	0,00	0,99	1,00	1,00	1,00	1,00	1,00	1,00
16	3,1	1,5	0,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00

1.3 Tabela de Resíduos Sistemáticos ($\Delta X = X_{\text{Zn}}^{\text{exp}} - X_{\text{PBM}}$)

(O sinal de correção físico-química que o Machine Learning aprende no Grey-Box)

Ensaio	η	CA0 (mol/L)	0 min	0,5 min	1 min	2 min	3 min	4 min	5 min	15 min
1	0,5	0,1	0,00	+0,10	+0,04	-0,02	-0,01	+0,01	-0,01	-0,00
2	3,1	0,1	0,00	+0,37	+0,22	+0,07	+0,02	-0,01	-0,00	+0,00
3	0,5	0,5	0,00	-0,04	-0,02	-0,01	+0,02	-0,00	-0,01	-0,00
4	0,5	1,0	0,00	+0,00	-0,03	+0,01	-0,03	+0,03	+0,01	-0,00
5	0,5	1,5	0,00	-0,01	-0,01	-0,03	-0,01	-0,01	-0,03	-0,01
6	1,0	0,1	0,00	+0,36	+0,21	+0,08	+0,05	+0,03	-0,02	-0,08
7	3,1	0,5	0,00	-0,04	-0,06	-0,02	-0,01	+0,00	-0,01	+0,01
8	1,0	0,5	0,00	+0,06	-0,05	-0,08	-0,09	-0,09	-0,11	-0,12
9	1,0	1,0	0,00	-0,04	-0,09	-0,11	-0,13	-0,15	-0,15	-0,15
10	1,0	1,5	0,00	-0,07	-0,12	-0,15	-0,15	-0,16	-0,15	-0,15
11	1,5	0,1	0,00	+0,44	+0,23	+0,07	+0,08	+0,01	+0,00	-0,02
12	3,1	1,0	0,00	-0,03	+0,00	+0,00	-0,01	-0,01	-0,01	+0,00
13	1,5	0,5	0,00	+0,06	-0,04	-0,05	-0,05	-0,05	-0,05	-0,03
14	1,5	1,0	0,00	-0,05	-0,04	-0,05	-0,03	-0,05	-0,02	-0,03
15	1,5	1,5	0,00	-0,08	-0,06	-0,05	-0,06	-0,04	-0,04	-0,03
16	3,1	1,5	0,00	-0,02	-0,02	-0,04	-0,01	-0,01	+0,00	+0,00

2. JUSTIFICATIVA

Na sua dissertação de 2017, para representar a desaceleração da lixiviação, foi introduzido um termo empírico na velocidade de dissolução:

$$v(t) = \frac{2}{\rho_s} [k_s C_{Af}(t) - \alpha (C_{A0} - C_{Af}(t))]$$

com o ajuste de $\alpha = 5500 \mu\text{m}/\text{min}$.

A Lacuna Identificada:

Esse parâmetro α concentra de forma estática fenômenos complexos que variam dinamicamente ao longo da reação:

- 1. **Efeito de Íon Comum:** O acúmulo de Zn^{2+} e sulfatos reduz a ação do ácido livre.

2. **Passivação Difusional por Sílica:** Formação de gel de sílica amorfa que recobre os poros das partículas.
3. **Morfologia dos Finos:** Partículas ultrafinas com cantos vivos (geometria não-esférica) dissolvem-se mais rápido nos primeiros 60 segundos do que esferas lisas.


A Proposta do Nosso TCC:

Em vez de depender de um parâmetro de ajuste empírico fixo (α), **vamos manter o modelo White-Box com $\alpha = 0$** e utilizar a técnica de **Modelagem Híbrida Grey-Box em Paralelo**, onde o Machine Learning aprende dinamicamente o comportamento físico-químico do resíduo (desvios do modelo teórico) :

$$\Delta X(t) = X_{\text{experimental}}(t) - X_{\text{PBM}}(t)$$

3. ARQUITETURA DO MODELO GREY-BOX

Abaixo apresentamos o fluxo de informação da arquitetura proposta:



3.1. Robustez do Modelo: E se a Granulometria do Minério Mudar?

Uma das maiores vantagens da arquitetura híbrida sobre redes neurais puras é a **sensibilidade granulométrica herdada da física**:

- Se um novo lote de calcina tiver uma moagem mais fina ($D_{63,2} = 25 \mu\text{m}$) ou mais grossa ($D_{63,2} = 60 \mu\text{m}$), o **ramo White-Box (PBM) recalcula analiticamente o 3º momento volumétrico e a dissolução de cada classe de tamanho**, sem necessidade de retreinar o algoritmo.
- O Machine Learning atua sobre o resíduo dimensional e cinético condicionado à nova previsão mecanicista, mantendo a estabilidade e prevenindo extrapolações absurdas.

3.2. Atributos de Entrada do Black-Box

Em uma abordagem híbrida de ponta (Physics-Informed Neural Networks), o modelo de Machine Learning **não recebe variáveis cegas**. Ele é alimentado por uma combinação de condições operacionais e variáveis de estado calculadas pela física:

#	Atributo (Feature)	Símbolo	Unidade	Origem	Papel Físico para o Machine Learning
1	Tempo de Lixiviação	t	min	Operacional	Localiza o estágio temporal da reação (início rápido vs. patamar tardio).
2	Razão Estequiométrica	η	adim.	Operacional	Informa se há falta ($\eta < 1$), equivalência ($\eta = 1$) ou excesso ($\eta > 1$) de ácido.
3	Ácido Inicial	C_{A0}	mol/L	Operacional	Define a acidez inicial e a força iônica máxima da solução aquosa.
4	Conversão da Física	$X_{\text{PBM}}(t)$	adim. (0 a 1)	White-Box	Fornecer uma linha de base física; a IA sabe onde a teoria mecanicista está operando.
5	Ácido Livre Teórico	$C_{Af, \text{teo}}$	mol/L	White-Box	Força-motriz ácida residual instantânea ($C_{A0}(1 - X_{\text{PBM}}/\eta)$); governa passivação e íon comum.
6	Esgotamento do Ácido	$\frac{X_{\text{PBM}}}{\eta}$	adim. (0 a 1)	White-Box	Alerta a IA quando a reação está próxima de travar por falta estequiométrica de reagente.

3.3. O Papel do Acoplador

O acoplador não é uma simples soma matemática; ele atua como o **filtro de consistência termodinâmica e operacional** da planta, impedindo que inconsistências físicas ocorram:

1. **Fusão estrutural:** Soma a base que carrega a física fundamental à correção fina aprendida pelo Machine Learning:

$$X_{\text{raw}}(t) = X_{\text{PBM}}(t) + \widehat{\Delta X}_{\text{ML}}(\mathbf{z})$$

2. **Garantia de não-alucinação e conservação de massa:** Algoritmos de ML podem extrapolar para valores irreais ($X < 0$ ou $X > 1$). O acoplador impede isso:

$$X_{\text{Híbrido}}(t) = \text{clip}(X_{\text{raw}}(t), 0, 0, 1, 0)$$

3. **Respeito à estequiometria:** Quando há falta de ácido ($\eta < 1,0$), não existem moléculas suficientes de H_2SO_4 para dissolver mais do que a fração η . O acoplador impede que o modelo preveja conversões fisicamente impossíveis:

$$X_{\text{Híbrido}}(t) \leq \eta \quad (\text{para } \eta < 1,0)$$

4. **Garantia de único sentido temporal:** A dissolução de calcina na batelada é irreversível (o zinco solubilizado não precipita espontaneamente de volta como rocha; $\frac{dX}{dt} \geq 0$). O acoplador elimina oscilações e quedas não-físicas entre

instantes sucessivos:

$$X_{\text{Híbrido}}(t_k) \geq X_{\text{Híbrido}}(t_{k-1})$$

4. METODOLOGIA: COMO FAREMOS A CONSTRUÇÃO DO GREY-BOX

O plano de execução está dividido em quatro etapas claras:

Etapla 1: Parâmetros utilizados

Em vez de alimentar o modelo de ML com variáveis puramente estatísticas ou cegas, forneceremos os **6 atributos** definidos na Seção 3.2, combinando condições operacionais e variáveis de estado termodinâmicas calculadas pela física:

1. **t (Tempo de Lixiviação):** Localiza o estágio temporal da reação (fase inicial acelerada vs. patamar tardio).
2. **η (Razão Estequiométrica):** Indica o regime de operação (falta quando $\eta < 1$, equivalência quando $\eta = 1$, ou excesso quando $\eta > 1$).
3. **C_{A0} (Concentração Inicial de Ácido):** Define a acidez inicial e a força iônica da polpa.
4. **$X_{\text{PBM}}(t)$ (Conversão White-Box):** Linha de base calculada pelo balanço populacional analítico.
5. **$C_{Af, \text{teórico}}$ (Ácido Livre Residual):** Força-motriz ácida instantânea ($C_{A0}[1 - X_{\text{PBM}}/\eta]$) que governa passivação e íon comum.
6. **X_{PBM}/η (Fração de Esgotamento):** Alerta estequiométrico que indica quando a reação cessa por exaustão de reagente.

Etapla 2: Treinamento e Seleção de Modelos

Testaremos e compararemos três algoritmos clássicos de regressão para aprender ΔX :

1. **Random Forest Regressor:** Excelente para capturar não-linearidades e interações sem risco de divergência.
2. **Multi-Layer Perceptron:** Base para modelos híbridos contínuos e PINNs.
3. **Support Vector Regression:** Robusto para pequenos conjuntos de dados amostrais.

Etapla 3: Validação Cruzada (Leave One Group Out)

Para garantir que o modelo **generaliza para condições operacionais não vistas** e não decorou os dados:

- O conjunto de 16 ensaios é dividido em 16 grupos.
- Em cada grupo, o modelo treina nos **outros 15 grupos** e é testado no **1 grupo deixado de fora**.
- Repete-se o processo 16 vezes, garantindo métricas de teste reais e sem vazamento de dados.

Etapla 4: Escalonamento e Validação na Planta Piloto Contínua

O modelo híbrido treinado na bancada será acoplado à **Distribuição de Tempos de Residência (DTR)** da Planta Piloto de 3 CSTRs em série (18 L cada), comparando as previsões com os dados reais de regime permanente ($Q = 0,41 \text{ L/min}$ e $0,21 \text{ L/min}$).
